Nama : Sania Luthfiani Nabila

NIM / Kelas : 23031554015 / 2023D

Mata Kuliah : Graf Sains Data

Penjelasan Hasil UTS Graf Sains Data

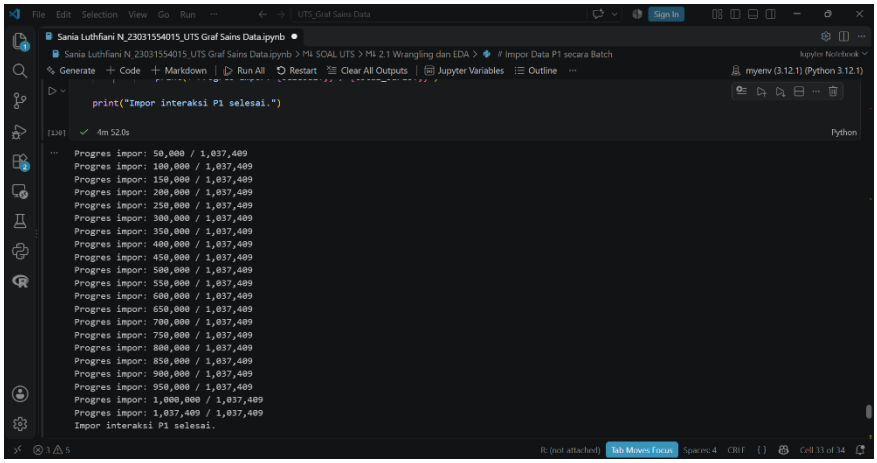
1. Persiapan dan pembagian dataset events P1 dan events P2
   Proses:
   Membaca dataset RetailRocket pada file events.csv. Selanjutnya memeriksa kolom, membersihkan data, menentukan mengkonversi timestamp, menentukan 2 periode waktu sebagai filter dari data interaksi dan membagi data menjadi P1 (training) dan P2 (testing).

   Output:
   Pada P1 memiliki data 1.037.409 event, periode 12 Mei–30 Juni 2015, 527.427 visitor, 152.588 item, dan 8.384 event transaksi. Sedangkan P2 memiliki data 309.637 event, periode 1–14 Juli 2015, 171.802 visitor, 83.507 item, dan 2.473 event transaksi.

   Analisis:
   P1 digunakan untuk membangun graf dan menghasilkan rekomendasi, sedangkan P2 digunakan untuk mengevaluasi rekomendasi. Kedua file tersebut berhasil disimpan sebagai P1_events.csv dan P2_events.csv.

2. Import interaksi P1 ke Neo4j
   Proses:
   Memasukkan data interaksi P1 ke Neo4j secara bertahap (batch) dengan query MERGE untuk membentuk node Visitor, node Item, dan relasi interaksi.

   Output:
   Proses impor mencapai 1.037.409 dari 1.037.409 baris dan menampilkan pesan Impor interaksi P1 selesai.



	jenis_relasi	jumlah
0	VIEWED	1003710
1	ADDED_TO_CART	25187
2	BOUGHT	8384
3	SIMILAR_TO	10
4	KNOWS	3

Analisis:
P1 digunakan untuk membangun graf dan menghasilkan rekomendasi, sedangkan P2 digunakan untuk mengevaluasi rekomendasi. Kedua file tersebut berhasil disimpan sebagai P1_events.csv dan P2_events.csv. Jumlah VIEWED, ADDED_TO_CART dan BOUGHT menunjukkan aktivitas pengguna yang tercatat. Relasi SIMILAR_TO dan KNOWS merupakan relasi tambahan, bukan jenis event utama data RetailRocket.

3. Mengambil data interaksi dari Neo4j
   Proses:
   Menjalankan query Cypher untuk mengambil hubungan visitor dengan item beserta jenis interaksinya.

   Output:
   Ukuran data interaksi adalah (1037281, 3), dengan kolom visitorId, itemId dan jenis_event.

   Analisis:
   Data tersebut menjadi masukan untuk membangun representasi matematis hubungan antara pengguna dan item. Jumlah barisnya lebih kecil sedikit daripada 1.037.409 data event yang diimpor, sehingga perlu diperiksa apakah query mengambil semua relasi interaksi atau melakukan penyaringan tertentu.

4. Membentuk VSM (Vector Space Modelling) User–Item
   Proses:
   Mengubah interaksi pengguna dan item menjadi matriks sparse. Baris merepresentasikan pengguna, sedangkan kolom merepresentasikan item. Nilai nonzero menunjukkan adanya interaksi.

   Output:
   Jumlah user: 527427
   Jumlah item: 152588
   Shape VSM User–Item: (527427, 152588)
   Jumlah interaksi unik: 800556

   Analisis:
   Matriks memiliki banyak elemen kosong karena setiap pengguna hanya berinteraksi dengan sebagian kecil dari seluruh item. Oleh karena itu, format sparse lebih hemat memori dibandingkan matriks biasa. Deduplicating pasangan pengguna dan item menghasilkan 800.556 pasangan unik dari data interaksi yang diambil.

5. Normalisasi VSM User dan Item
   Proses:

Membuat dua representasi dari matriks User–Item, lalu melakukan normalisasi L2.

Output:
Shape VSM User: (527427, 152588)
Shape VSM Item: (152588, 527427)

Analisis:
VSM User digunakan untuk membandingkan pengguna berdasarkan item yang pernah mereka akses. VSM Item digunakan untuk merepresentasikan item berdasarkan pengguna yang berinteraksi dengannya. Normalisasi membantu membandingkan vektor berdasarkan arah atau pola, bukan sekadar besarnya nilai.

6. Menghitung kepadatan matriks (density)
   Proses:
   Menghitung proporsi elemen nonzero dibandingkan seluruh elemen matriks.

   Output:
   Density yang ditampilkan sekitar 0.00001.

   Analisis:
   Matriks sangat jarang (sparse), ini termasuk kebiasaan pada sistem rekomendasi karena jumlah kombinasi seluruh user dan item sangat besar, sementara interaksi aktual jauh lebih sedikit.

7. Membentuk graf bipartit dan graf proyeksi
   Proses:
   Membentuk graf bipartit yang menghubungkan pengguna dengan item, kemudian membuat dua proyeksi yaitu User Projection dan Item Projection. Sampel yang digunakan disini 100 sampel, karena jika dicoba melebihi 100 dapat membuat memori lebih cepat penuh atau laptop menjadi lebih lambat.

   Output:
   Graf bipartit: 104 node, 100 edge
   Proyeksi User: 99 node, 2111 edge
   Proyeksi Item: 5 node, 1 edge

   Analisis:
   Graf bipartit menggambarkan hubungan langsung pengguna dengan item. Pada User Projection, 2 pengguna terhubung jika memiliki item yang sama. Pada Item Projection, 2 item terhubung jika memiliki ID pengguna yang sama.

8. Membandingkan karakteristik graf proyeksi
   Proses:
   Menghitung jumlah node, edge, density, komponen terhubung, waktu pembentukan proyeksi.

   Output:

Proyeksi User memiliki 2.111 edge dan density 0.435168, sedangkan Proyeksi Item memiliki 1 edge dan density 0.100000. pada waktu proses, Proyeksi User 0.006136 detik dan Proyeksi Item 0.000154 detik.

Analisis:
Proyeksi User pada sampel tersebut lebih rapat karena banyak pengguna berbagi item yang sama. Proyeksi Item hanya memiliki sedikit hubungan karena sampel yang digunakan hanya memuat lima item. Pada pengujian, waktu Proyeksi Item lebih cepat dibentuk.

9. Menghitung kemiripan pengguna
   Proses:
   Menghitung tingkat kemiripan antara pengguna acuan dan pengguna lain, kemudian mengurutkan nilai similarity dari tertinggi.

   Output:
   Record acuan yang dibuat U111016. Lima pengguna teratas memiliki nilai similarity 0.833333.

   Analisis:
   Nilai tersebut menunjukkan kemiripan pola yang relatif tinggi menurut representasi yang digunakan dalam perhitungan. Semakin mendekati 1, semakin mirip kedua representasi pengguna; nilai 0 menunjukkan tidak ada kemiripan pada dimensi yang dibandingkan. Namun, jika similarity pada project ini dihitung dari graf proyeksi yang hanya dibangun menggunakan 100 interaksi, hasilnya hanya mencerminkan sampel kecil tersebut.

10. Menyimpan similarity ke Neo4j
    Proses:
    Menyimpan hubungan SIMILAR_TO antara pengguna acuan dan lima pengguna yang paling mirip, beserta nilai similarity-nya.

    Output:
    Pesan Similarity berhasil disimpan ke Neo4j.

    Analisis:
    Relasi similarity memungkinkan hubungan kemiripan pengguna ditelusuri langsung di graf Neo4j. Contohnya, record acuan dapat dihubungkan dengan lima pengguna tetangga yang memiliki nilai similarity tertinggi. Visualisasi sebelum penambahan relasi menunjukkan 2 node dan 1 edge, sedangkan sesudahnya 7 node dan 6 edge. Hal ini konsisten dengan penambahan lima hubungan dari satu pengguna acuan ke lima pengguna lain. Dengan asumsi bahwa kelima pengguna tersebut sebelumnya belum termasuk ke dalam visualisasi.

11. Membuat rekomendasi dengan KNN
    Proses:
    Membaca dataset RetailRocket pada file events.csv. Selanjutnya memeriksa kolom, membersihkan data, menentukan mengkonversi timestamp, menentukan 2 periode waktu sebagai filter dari data interaksi dan membagi data menjadi P1 (training) dan P2 (testing).

    Output:

ID numerik user target: 899857
Jumlah item yang sudah dikenal target: 75

User target : U899857
Jumlah tetangga yang ditemukan: 5

	user_mirip	similarity	visitorid
0	U1404133	0.983606	1404133
2	U819547	0.983606	819547
30	U1370334	0.983606	1370334
3	U439857	0.983606	439857
4	U1394288	0.983606	1394288

5 rekomendasi teratas

	itemid	skor_rekomendasi
20	265760	11.803273
24	281480	6.885243
42	443344	4.918031
15	158575	3.934424
23	278208	3.934424

User target: U899857

3 Item yang Direkomendasikan untuk k = 5

	itemid	skor_rekomendasi
20	265760	11.803273
24	281480	6.885243
42	443344	4.918031

Analisis:
Analisis ketetanggaannya yaitu elima tetangga memiliki tingkat kemiripan yang tinggi menurut metode yang digunakan. Sistem lalu memanfaatkan item yang berinteraksi dengan tetangga tersebut untuk menyusun kandidat rekomendasi bagi pengguna target. Analisis skornya yaitu pada Item 265760 memperoleh skor tertinggi, sehingga menjadi kandidat rekomendasi utama berdasarkan perhitungan yang kamu lakukan. Skor yang lebih tinggi berarti item tersebut mendapat dukungan lebih besar dari tetangga pengguna.

12. Evaluasi rekomendasi menggunakan data P2
Proses:
Ini adalah tahap terakhir dalam melakukan evaluasi dengan mengambil item transaksi pengguna target pada P2 sebagai item relevan, kemudian membandingkannya dengan lima rekomendasi yang dihasilkan dari P1.

Output:

```
User target: U899857
ID target numerik: 899857
Jumlah item relevan pada P2: 9
Item relevan: {np.int64(251204), np.int64(213255), np.int64(335276), np.int64(232172), np.int64(124559), np.int64(349047), np.int64(42997), np.int64(8
```

```
Hasil Hit@5: 0
Hasil NDCG@5: 0.0
```

Analisis:
Nilai Hit@5 sebesar 0 menunjukkan bahwa tidak ada item relevan dari transaksi P2 pengguna target yang ditemukan di lima rekomendasi teratas. NDCG@5 sebesar 0 menunjukkan bahwa tidak ada item relevan yang memperoleh posisi pada daftar lima rekomendasi tersebut.